


谱聚类与图划分

从图割到拉普拉斯谱松弛



课程议程


01



模块一：问题引入
什么是好的图划分？

预计用时：5分钟

02



模块二：数学建模
图割与优化目标

预计用时：8分钟


03

$$A = \begin{pmatrix} 1 & 1 & v_1 \\ 0 & 1 & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & v_n \end{pmatrix} \in \mathbb{R}^{n \times 3}$$

模块三：核心理论
拉普拉斯矩阵与谱松弛

预计用时：10分钟

04



模块四：算法实现与总结
谱聚类算法流程及应用


预计用时：7分钟

回顾：图的代数表示 A 与 D

核心概念：如何让计算机理解一个图？关键在于将图的几何结构转化为可计算的代数形式。

邻接矩阵 (Adjacency Matrix) A : $n \times n$ 矩阵
中 $A_{ij} = 1$ 表示节点 i 和 j 有连接边，否则 0。

度矩阵 (Degree Matrix) D : $n \times n$ 对称矩阵
并为对角线元素 $D_{ii} = \text{节点 } i \text{ 的度数}$ 。



$$A = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

$$D = \begin{pmatrix} D_{11} & 0 & 0 & 0 \\ 0 & D_{22} & 0 & 0 \\ 0 & 0 & D_{33} & 0 \\ 0 & 0 & 0 & D_{44} \end{pmatrix}$$


$$D = \begin{pmatrix} D_{11} & 0 & 0 & 0 \\ 0 & D_{22} & 1 & 0 \\ 0 & 0 & D_{33} & 1 \\ 0 & 0 & 1 & D_{44} \end{pmatrix}$$

示例转换

从左侧图形到右侧矩阵的转换过程，
体现了图论中“几何直观”与“代数计算”
的完美结合

引入：图划分的任务目标

- **问题定义：** 将图 $G = (V, E)$ 的顶点集 V 划分为两个互不相交的子集 A 和 B
- **核心目标：**
 - 最大化组内连接 - 同一组内的节点之间连接紧密
 - 最小化组间连接 - 不同组之间的连接尽可能少



'物以类聚，人以群分'
— 一个好的划分应该体现这一朴素原则


定义：图割 (Graph Cut)

- 定义：图割是指将图的顶点集 V 划分为两个互不相交的子集 A 和 B 时，连接这两个子集之间的所有边的集合。

$$\text{Cut}(A, B) = \sum_{(i,j) \in E, i \in A, j \in B} w_{ij}$$

- 符号说明：

- A, B ：两个互不相交的顶点子集 ($A \cap B = \emptyset, A \cup B = V$)
- w_{ij} ：边 (i, j) 的权重
- 该公式计算所有跨组边的权重之和



优化准则：最小割 (Minimum Cut)

核心思想：直接最小化组间连接的总权重


数学表达： $Cut(A, B) = \sum w_{ij}$ (其中 $i \in A, j \in B$)

优化目标： $\min Cut(A, B)$

subject to $A \cup B = V, A \cap B = \emptyset$

直观理解：'割掉'连接两个组的边，使得组间联系最少

物理意义：最小化跨组边的权重总和



最小割的致命缺陷：退化问题

- 问题描述：

最小割准则存在严重的退化问题（Degenerate Case），当图中存在度数很低的孤立节点时，算法倾向于将其单独划分为一个组。



- 核心缺陷：

- 只关注组间连接的数量
- 完全忽略组内部的连通性
- 导致极不平衡的划分结果

- 根本原因：

最小割准则 $\min \text{Cut}(A,B)$ 仅最小化跨组边的权重，而不考虑每个组的内部结构和规模。

一个组即使内部连接稀疏，只要它与外部连接少，就可能被“割”出来



改进准则：归一化割 (Normalized Cut)

- **核心概念：组容量 (Volume)**

- 组 A 的容量： $\text{vol}(A) = A$ 中所有节点的度数之和
- 衡量组与整个图的连接强度


- **归一化割公式：**

$$\text{Ncut}(A, B) = \frac{\text{Cut}(A, B)}{\text{vol}(A)} + \frac{\text{Cut}(A, B)}{\text{vol}(B)}$$

- **优势特性：**



- 自动惩罚容量过小的组
- 倾向于产生容量相近的划分
- 避免孤立节点被单独切出

归一化割通过相对比较解决了最小割的不平衡问题，是谱聚类的数学基础



计算挑战：NP-hard 复杂性

- 问题本质：寻找最优图划分属于 NP-hard 问题类别
- 计算复杂度：随着图规模增大，穷举所有可能划分的时间复杂度呈指数数级增长
- 实际影响：对于包含 n 个节点的图，可能的划分数量为 2^{n-1}
- 现实困境：当 $n > 30$ 时，精确求解在现实时间内变得不可行



****解决方案****

我们必须放弃寻找精
最优解，转而寻求高
效的近似求解方法



谱图理论登场

$\lambda_1, \lambda_2, \lambda_3 \dots$
spectral solution

核心工具：拉普拉斯矩阵 L


- 拉普拉斯矩阵是谱聚类的数学基础，定义为：

$$L = D - A$$


- 其中：
 - D 是度矩阵（对角矩阵）
 - A 是邻接矩阵

重要性质

- 对称矩阵： $L = L^T$
- 行和为零：每行元素和为 0
- 半正定： $x^T L x \geq 0$



实例演示：拉普拉斯矩阵的构建



Step 1. 邻接矩阵 A

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 & 0 \end{bmatrix}$$

Step 2. 度矩阵 D

$$D = \begin{bmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$

Step 3. 拉普拉斯矩阵 $L = D - A$

$$L = \begin{bmatrix} 2 & -1 & -1 & 0 & 0 \\ -1 & 4 & -1 & -1 & -1 \\ -1 & -1 & 3 & -1 & 0 \\ 0 & -1 & -1 & 3 & -1 \\ 0 & -1 & 0 & -1 & 2 \end{bmatrix}$$

每行每列的都为 0
非对角线元素为非正

Key Observations

- L 是对称矩阵
- 每行每列的和都为 0
- 对角线元素为正，非对角线元素为非正

物理意义：二次型展开式

拉普拉斯矩阵的二次型 $\mathbf{x}^T \mathbf{L} \mathbf{x}$ 具有深刻的物理意义。通过代数展开：


$$\mathbf{x}^T \mathbf{L} \mathbf{x} = \mathbf{x}^T (\mathbf{D} - \mathbf{A}) \mathbf{x} = \mathbf{x}^T \mathbf{D} \mathbf{x} - \mathbf{x}^T \mathbf{A} \mathbf{x}$$

其中：

$$\mathbf{x}^T \mathbf{D} \mathbf{x} = \sum_i d_i x_i^2$$

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{(i,j) \in E} 2w_{ij} x_i x_j$$

$$\mathbf{x}^T \mathbf{L} \mathbf{x} = \sum_{(i,j) \in E} w_{ij} (x_i - x_j)^2$$




最小化 $\mathbf{x}^T \mathbf{L} \mathbf{x}$ 等价于让每条边 (i, j) 两端的节点值 x_i 和 x_j 尽可能接近

性质一：拉普拉斯矩阵的半正定性

拉普拉斯矩阵 $L = D - A$ 具有重要的半正定性，这是谱聚类理论的数学基石。

- 定义回顾：矩阵 M 是半正定的，当且仅当对所有向量 x ，都有 $x^T M x \geq 0$
- L 的半正定性：对于任意实向量 x ，恒有 $x^T L x \geq 0$
- 重要推论： L 的所有特征值 $\lambda_i \geq 0$ (非负实数)

$$x^T L x = \sum_{(i,j) \in E} w_{ij} (x_i - x_j)^2 \geq 0$$



半正定性保证了谱聚类优化问题有良好的数学性质，使基于特征值分解的算法具有理论可靠性。

定理证明：L 的半正定性推导

定理陈述：对于任意无向图 G 的拉普拉斯矩阵 $L = D - A$ ，以及任意实向量 $x \in \mathbb{R}^n$ ，恒有 $x^T L x \geq 0$ 。

证明过程：

步骤1：展开二次型表达式


$$x^T L x = x^T (D - A) x = x^T D x - x^T A x$$

步骤2：分别计算两个分量

步骤3：关键变形

$$\begin{aligned} x^T L x &= \sum_{(i,j) \in E} w_{ij} (x_i^2 + x_j^2 - 2x_i x_j) \\ &= \sum_{(i,j) \in E} w_{ij} (x_i - x_j)^2 \end{aligned}$$

结论：由于 $w_{ij} \geq 0$ 且 $(x_i - x_j)^2 \geq 0$ ，所以 $x^T L x \geq 0$ □



性质二：平凡特征对与最小特征值

定理陈述：对于任意无向图 G 的拉普拉斯矩阵 L ，其最小特征值 $\lambda_1 = 0$ ，对应的特征向量为全1向量 $\mathbf{1} = (1, 1, \dots, 1)^T$

证明过程：设 $\mathbf{1} = (1, 1, \dots, 1)^T$ 为 n 维全1向量，我们需要验证 $L\mathbf{1} = \mathbf{0}$ 。


由拉普拉斯矩阵的定义 $L = D - A$ ，我们有： $L\mathbf{1} = (D - A)\mathbf{1} = D\mathbf{1} - A\mathbf{1}$ 。

计算 $D\mathbf{1}$ ：由于 D 是度矩阵， $D\mathbf{1} = (d_1, d_2, \dots, d_n)^T$ ，其中 d_i 是节点 i 的度数。 $\mathbf{1} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$

计算 $A\mathbf{1}$ ： $A\mathbf{1}$ 的第 i 个分量是 $\sum_j A_{ij} = d_i$ （节点 i 的度数），因此 $A\mathbf{1} = (d_1, d_2, \dots, d_n)^T$ 。

结论： $L\mathbf{1} = D\mathbf{1} - A\mathbf{1} = (d_1, d_2, \dots, d_n)^T - (d_1, d_2, \dots, d_n)^T = \mathbf{0}$ 。

因此 $\lambda_1 = 0$ ，对应特征向量为 $\mathbf{1}$



性质三：连通性与特征值重数

核心定理：图 G 的连通分量个数 = 拉普拉斯矩阵 L 中特征值 0 的代数重数

数学表达：设图 G 有 k 个连通分量



$$\lambda_1 = \lambda_2 = \dots = \lambda_k = 0$$

且 $\lambda_{k+1} > 0$

重要推论：



- 连通图： $\lambda_1 = 0, \lambda_2 > 0$ (Fiedler值为正)
- 断开图：存在多个零特征值
- 完全断开：每个节点都是独立分量

单连通图 (1个连通分量)




$$\lambda_1 = 0, \lambda_2 > 0$$

单连通图 (1个连通分量)



$$\lambda_1 = \lambda_2 = 0, \lambda_3 > 0$$

双连通分量 (2个连通分量)



$$\lambda_1 = \lambda_2 = \lambda_3 = 0, \lambda_4 > 0$$

三个孤立点 (3个连通分量)

直观理解：每个连通分量都有自己的“全1特征向量”，这些向量线性无关，因此零特征值的个数等于连通分量数

矩阵变体：归一化拉普拉斯矩阵

1. 问题背景

- 标准拉普拉斯矩阵 $L = D - A$ 在处理度分布不均的图时存在局限性
- 高度节点会主导特征向量的计算结果

归一化处理的核心优势：消除度数差异的影响，使算法对图的局部度变化更加鲁棒

2. 对称归一化拉普拉斯矩阵



定义： $L_{sym} = D^{-\frac{1}{2}}LD^{-\frac{1}{2}} = I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$

- 特点：保持矩阵的对称性，特征值范围在 $[0, 2]$ 之间

3. 随机游走归一化拉普拉斯矩阵

定义： $L_{rw} = D^{-1}L = I - D^{-1}A$

- 特点：与随机游走过程直接相关，处理非对称但稳定



谱松弛技术：从离散到连续


• 原始离散问题

- 寻找 $x \in \{+1, -1\}^n$ 使得 $x^T L x$ 最小
- 节点标签: $x_i = +1$ (属于簇A) 或 $x_i = -1$ (属于簇B)
- 组合优化: 需要枚举 2^n 种可能的划分
- 计算复杂性: NP-hard 问题

• 谱松弛变换

将离散约束松弛为连续约束:

- 离散 $\rightarrow$ 连续: $x_i \in \{+1, -1\} \rightarrow x_i \in R$
- 添加约束: $\|x\|^2 = n$ 和 $x^T \mathbf{1} = 0$
- 新优化问题: $\min_{x \in R^n, x^T \mathbf{1} = 0} x^T L x$



关键洞察

松弛后的问题有闭式解: 最优解是拉普拉斯矩阵 L 的第二小特征值 λ_2 对应的特征向量 (Fiedler向量)

瑞利商定理与 Fiedler 向量

瑞利商优化问题

根据瑞利商定理，约束优化问题：

$$\min_{x \in \mathbb{R}^n} \frac{x^T L x}{x^T x} \quad \text{s.t.} \quad x^T \mathbf{1} = 0$$


核心定理

- 最小值等于拉普拉斯矩阵 L 的第二小特征值 λ_2
- 最优解 x^* 是对应的特征向量 (Fiedler 向量)
- Fiedler 向量提供图的"最佳一维嵌入"

几何直观

Fiedler 向量将图节点映射到实数轴上，使得：

- 相连节点的值尽可能接近
- 不同簇的节点自然分离



$$\text{eigenvector} = x^T L x = 0$$

Fiedler 向量的物理意义：节点在向量上的值反映了它们在图中的'位置关系'，为图划分提供了天然的分界线。

理论保障：近似解的可靠性

核心定理

- Cheeger 不等式 (Cheeger Inequality)

$$\frac{\lambda_2}{2} \leq h(G) \leq \sqrt{2\lambda_2}$$

符号说明

λ_2 : 拉普拉斯矩阵的第二小特征值


$h(G)$: 图的 Cheeger 常数 (最优归一化割)

• Key Points

- 谱方法提供了可证明的近似保证
- 找到的解与最优解之间存在有界的关系
- 第二小特征值 λ_2 越小，图的可分性越好

实际意义

谱聚类算法始终能给出一个有用的边界，保证近似解的可靠性。即使无法找到绝对最优解，我们也能确信结果在理论上是合理的。



谱聚类算法流程：三大阶段

Phase 1 - 预处理 (Pre-processing)


- 构建相似度矩阵 W
- 计算度矩阵 D
- 生成拉普拉斯矩阵 $L = D - A$

Phase 2 - 分解 (Decomposition)



- 计算 L 的特征值和特征向量
- 提取前 k 个最小非零特征值
- 构建特征矩阵 $U_{n \times k}$

Phase 3 - 分组 (Grouping)

- 将 U 的每行为 k 维向量
- 应用 K-Means 等传统聚类算法
- 得到最终的 k 个簇





谱聚类算法例子 (1)






谱聚类算法例子 (2)

Components of $\mathbf{x}_2$



谱聚类算法例子 (3)



多簇划分策略：k-Way 谱聚类


递归二分法

方法一：递归二分法 (Recursive Bipartitioning)


- 反复应用二分谱聚类
- 逐步细分图的结构
- 映软力分法

缺点列表

- 计算效率低下
- 误差可能累积
- 局部最优问题
- 结果不稳定



推荐使用




多特征向量法

方法二：多特征向量聚类法 (Multi-eigenvector Clustering)

- 同时计算前 k 个特征向量
- 构成 $n \times k$ 特征矩阵 U
- 对行向量进行 K-means 聚类

优势列表

- 保留图的全局结构
- 结果更加稳定
- 计算效率更高
- 主流推荐方法



多特征向量法能更好地捕获图的全局几何结构


典型应用：图像分割与社交网络分析

图像分割

- 像素作为图节点
- 相似度构建边权重
- 自动识别语义区域

应用场景

- 医学图像分析
- 计算机视觉
- 内容检索




社交网络分析

- 个人/组织为节点
- 互动关系为边
- 发现紧密社群

应用场景


- 个性化推荐
- 舆情监控
- 网络安全分析



课程总结与课后练习

课程核心要点

- 定义好划分：归一化割准则实现"物以类聚"
- 近似求解：谱松弛将NP-hard问题转为特征值问题
- 核心工具：拉普拉斯矩阵 $L = D - A$ 及其谱性质
- 算法流程：预处理 $\rightarrow$ 分解 $\rightarrow$ 分组三大阶段



课后练习题

练习一：4节点环形图计算

给定环形图 1-2-3-4-1, 计算：

- 邻接矩阵 A
- 度矩阵 D

练习二：理论证明

证明：对任意无向图，拉普拉斯矩阵 L 的行和与列和均为0

练习三：特征值性质

证明：连通图的拉普拉斯矩阵第二小特征值 $\lambda_2 > 0$